

Big Data

Actividad en Grupo: Big Data en la Práctica Duración: 60 - 75 minutos

Objetivos:

- Aplicar una visión integral del ecosistema de Big Data a escenarios reales.
- Conectar los conceptos teóricos (5 V's, almacenamiento, procesamiento, etc.) con sus aplicaciones prácticas.
- Fomentar el pensamiento crítico, la investigación y la colaboración en grupo.
- Desarrollar habilidades de presentación y comunicación de hallazgos.

Instrucciones para los Alumnos:

1. Formación de Grupos:

- Utilizar los grupos ya creados en la clase anterior.

2. Asignación del Caso de Estudio:

- A cada grupo se le asignará uno de los casos de uso real (se encuentran al final del documento).

3. Investigación y Discusión:

- En tu grupo, analicen en profundidad el caso de estudio asignado.
- Utilicen los siguientes puntos como guía para su análisis y tomen notas de sus respuestas:
 - **1. Las 5 V's del Big Data:**
 - Volumen: ¿Qué tipo de datos masivos se generan o manejan? ¿De qué escala hablamos (terabytes, petabytes)?
 - Velocidad: ¿Los datos se procesan en tiempo real o por lotes? ¿Por qué esa velocidad es crucial para el éxito de la empresa?
 - Variedad: ¿Qué tipos de datos se utilizan (estructurados, no estructurados, semi-estructurados)?
 - Veracidad: ¿Qué desafíos de calidad y confiabilidad de datos podrían enfrentar?
 - Valor: ¿Cuál es el beneficio de negocio (ganancias, eficiencia, satisfacción del cliente) que se obtiene del Big Data en este caso?
 - **2. Almacenamiento:** ¿Dónde se almacenarán estos datos? ¿Creen que sería un sistema de archivos distribuido como HDFS, un Data Lake o una base de datos más tradicional? ¿Qué desafíos de escalabilidad y costo enfrentarían al almacenar estos datos?
 - **3. Procesamiento y Análisis:**
 - ¿Qué tipo de procesamiento se necesita (por lotes o en streaming)?
 - ¿Qué herramientas de análisis serían las más adecuadas (ej. SQL, Python, machine learning)?
 - **4. Gobernanza y Seguridad:**
 - ¿Qué datos sensibles o personales podrían estar manejando? (ej. datos personales de clientes, historial de navegación)?
 - ¿Qué desafíos de seguridad y privacidad tendrían que considerar para proteger la información?

4. Presentación de Hallazgos:

- Al finalizar el tiempo de discusión, cada grupo presentará un resumen de su análisis al resto de la clase. El objetivo es compartir una visión integral del caso de estudio, conectando todos los puntos analizados.

Caso de Estudio 1: Empresa de Streaming (Netflix)

- Caso de Uso: Optimización de la experiencia del usuario y creación de contenido original.
- Descripción Ampliada: Netflix, como líder en streaming, no solo compite con otras plataformas, sino también con el tiempo libre de sus usuarios.

Para mantenerlos enganchados, utiliza Big Data para todo:

- Motor de Recomendaciones: Recopila datos de miles de millones de interacciones, incluyendo qué ven los usuarios, qué buscan, a qué hora, qué dispositivos usan, cuándo pausan, rebobinan o abandonan un título. Con esta información, el 80% del contenido que un usuario ve proviene de su motor de recomendaciones.
- Creación de Contenido Original: Antes de producir una serie, Netflix analiza qué actores, directores y géneros son populares en diferentes regiones. Los datos les indican qué historias tienen la mayor probabilidad de ser un éxito, lo que justifica la enorme inversión en producción.
- Optimización del Producto: Mediante pruebas A/B a gran escala, Netflix experimenta con diferentes diseños de interfaz y miniaturas de series para ver qué genera más clics y tiempo de visualización.

Netflix

Caso de estudio: Netflix y Big Data

Netflix usa Big Data principalmente para tres cosas: recomendar contenido, decidir qué series o películas producir y mejorar la aplicación mediante pruebas con distintos diseños y miniaturas.

1. Las 5 V del Big Data

Volumen:

Netflix recopila miles de millones de datos sobre el comportamiento de sus usuarios: qué miran, qué buscan, cuándo pausan, qué abandonan, cuánto tiempo permanecen mirando y qué dispositivo utilizan. Debido a la cantidad de usuarios y de interacciones, se puede hablar de una escala de petabytes.

Velocidad:

Algunos datos se procesan casi en tiempo real. Por ejemplo, Netflix puede modificar las recomendaciones según lo que una persona acaba de mirar. Otros datos se analizan por lotes, como los resultados mensuales de una serie o las preferencias generales de cada país.

Esta velocidad es importante porque permite adaptar rápidamente la plataforma a los gustos de cada usuario.

Variedad:

Netflix utiliza diferentes tipos de datos:

- Estructurados: usuario, país, dispositivo, horario y duración.
- Semiestructurados: registros de clics, búsquedas y reproducciones.
- No estructurados: imágenes, miniaturas, trailers, subtítulos y descripciones.

Veracidad:

No todos los datos muestran exactamente lo que le gusta a una persona. Por ejemplo, una cuenta puede ser utilizada por varias personas, alguien puede reproducir algo por error o abandonar una película porque fue interrumpido. También puede haber datos incompletos, repetidos o problemas de conexión.

Netflix debe limpiar y revisar la información antes de utilizarla.

Valor:

El principal beneficio es mejorar la experiencia del usuario. Las recomendaciones permiten encontrar contenido más rápido, aumentar el tiempo de visualización y reducir las cancelaciones.

Además, Netflix puede conocer qué géneros, actores o directores interesan en cada región antes de invertir en una producción original. Las pruebas A/B también permiten elegir la interfaz o miniatura que genera más clics.

2. Almacenamiento

Una base de datos tradicional no sería suficiente para guardar toda la información. Netflix necesitaría combinar:

- Un Data Lake para almacenar grandes cantidades de datos en distintos formatos.
- Sistemas distribuidos para repartir la información entre muchos servidores.
- Bases de datos para información más organizada, como cuentas y perfiles.

HDFS podría servir como ejemplo de almacenamiento distribuido, porque divide los archivos en bloques y los guarda en distintas computadoras. Sin embargo, una empresa como Netflix trabaja principalmente con infraestructura distribuida en la nube.

Los principales desafíos son el costo de almacenar tanta información, el crecimiento constante de los datos, la necesidad de acceder rápidamente a ellos y la protección frente a pérdidas o fallas.

3. Procesamiento y análisis

Netflix necesita los dos tipos de procesamiento:

Procesamiento en streaming: analiza eventos mientras ocurren. Se utiliza para registrar reproducciones, actualizar recomendaciones y detectar problemas técnicos.

Procesamiento por lotes: analiza grandes cantidades de datos históricos. Se utiliza para estudiar tendencias, evaluar el éxito de una serie y entrenar los modelos de recomendación.

Las herramientas adecuadas serían:

- **SQL:** consultar datos de usuarios, títulos y reproducciones.
- **Python:** limpiar y analizar la información.
- **Spark:** procesar grandes cantidades de datos rápidamente.
- **Machine Learning:** recomendar contenido y encontrar patrones.
- **Herramientas de visualización:** mostrar los resultados en gráficos y tableros.
- **Pruebas A/B:** comparar diseños, funciones y miniaturas.

Por ejemplo, Netflix puede mostrar dos miniaturas diferentes de una serie a distintos grupos. Después compara cuál consiguió más clics y utiliza la que tuvo mejores resultados.

4. Gobernanza y seguridad

Netflix maneja información personal y sensible, como:

- Nombre y correo electrónico.
- Datos de la cuenta y del medio de pago.
- Dirección IP y ubicación aproximada.
- Dispositivo utilizado.
- Historial de búsquedas y reproducciones.
- Horarios y hábitos de uso.

- Preferencias personales.

Para protegerla, Netflix debe controlar quién puede acceder, encriptar la información, registrar los accesos y cumplir las leyes de privacidad. También debe definir durante cuánto tiempo conserva los datos y eliminarlos cuando dejan de ser necesarios.

El desafío es aprovechar la información para personalizar la plataforma sin invadir la privacidad de los usuarios.