Trabajo Práctico de Big Data

Análisis y clasificación de alimentos con Orange Data Mining

1. Introducción y objetivo

El objetivo de este trabajo fue utilizar Orange Data Mining para comparar tres modelos de Machine Learning: árbol de decisión (Tree), regresión logística (Logistic Regression) y red neuronal (Neural Network).

Se trabajó con una base de datos de 35 alimentos, divididos en 25 para entrenamiento y 10 para prueba. Cada alimento contiene información nutricional, como vitaminas, calorías, proteínas y minerales.

El propósito fue evaluar qué modelo logra clasificar con mayor precisión los alimentos en frutas y verduras.

2. Resultados y análisis

Después de entrenar los tres modelos en Orange, utilizamos 10 alimentos de prueba para evaluar su capacidad de clasificación.

Los resultados fueron los siguientes:

- **Tree (Árbol de decisión):** 40% de precisión, clasificando correctamente 4 de 10 alimentos.
- **Logistic Regression (Regresión logística):** 70% de precisión, clasificando correctamente 7 de 10 alimentos.
- **Neural Network (Red neuronal):** 80% de precisión, clasificando correctamente 8 de 10 alimentos.

El modelo que obtuvo mejores resultados fue **Neural Network**, con un 80% de aciertos.

Mediante la matriz de confusión observamos que clasificó correctamente 5 frutas y 3 verduras, mientras que cometió 2 errores.

Esto demuestra que, para este conjunto de datos de prueba, la red neuronal fue la alternativa más efectiva. Sin embargo, al tratarse de una muestra pequeña, los resultados no garantizan que tenga el mismo rendimiento con otros alimentos.

3. Conclusión

A través de este trabajo práctico pudimos utilizar Orange Data Mining para entrenar y comparar diferentes modelos de Machine Learning, con el objetivo de clasificar alimentos según sus características nutricionales.

Los resultados mostraron que la red neuronal fue el modelo con mejor desempeño, alcanzando un 80% de aciertos, seguida por la regresión logística con un 70% y el árbol de decisión con un 40%.

En conclusión, el trabajo permitió comprender cómo se pueden utilizar los datos para entrenar modelos predictivos, comparar sus resultados y evaluar cuál funciona mejor para un problema determinado.

También observamos que los modelos pueden cometer errores y que es importante contar con una mayor cantidad de datos para obtener resultados más confiables.

